

Tema 3

Variables aleatorias y modelos de distribuciones

3.1 Conceptos generales

Definición 3.1.1.— Dado un espacio de probabilidad (Ω, \mathcal{A}, P) , una variable aleatoria es una función $X : \Omega \longrightarrow \mathbb{R}$.

Ejemplos de variables aleatorias:

- Se lanza una moneda dos veces y a cada resultado se le asigna el número de caras obtenidas:
 $\omega_1 = (c, c) \quad X(\omega_1) = 2$
 $\omega_2 = (c, x) \quad X(\omega_2) = 1$
 $\omega_3 = (x, c) \quad X(\omega_3) = 1$
 $\omega_4 = (x, x) \quad X(\omega_4) = 0$
- Se lanzan dos dados y a cada resultado se le asigna la suma de los números que han salido.
- Se dispara a una diana y se asigna a cada impacto la distancia desde éste hasta el centro de la diana.

Definición 3.1.2.— Una variable aleatoria se dice que es discreta cuando su recorrido es un número finito o infinito numerable de valores. En otro caso, por ejemplo si el recorrido es un intervalo, se dice que la variable es continua.

En los ejemplos anteriores los dos primeros casos corresponden a variables aleatorias discretas, y el tercero a una variable aleatoria continua.

Nota: el que una variable aleatoria sea continua o discreta no viene determinado por el espacio muestral, sino por su recorrido.

Proposición 3.1.3.— Si X es una variable aleatoria sobre Ω y f es una función continua, $f : D \subset \mathbb{R} \longrightarrow \mathbb{R}$, tal que $\text{Img}(X) \subseteq D$ entonces $f \circ X : \Omega \longrightarrow \mathbb{R}$ es una variable aleatoria que denotaremos $f(X)$, y se define como:

$$f(X)(\omega) = (f \circ X)(\omega) = f(X(\omega)) \quad \forall \omega \in \Omega$$

En particular, si X e Y son variables aleatorias sobre Ω y $a, b \in \mathbb{R}$, entonces aX , $aX + bY$ y XY son variables aleatorias.

3.2 Variables aleatorias discretas

Definición 3.2.1.— Dada una variable aleatoria X que toma los valores $x_1, x_2, \dots, x_n, \dots$ se llama función de probabilidad o distribución de probabilidad a la función:

$$P : \mathbb{R} \longrightarrow [0, 1]$$

$$P(x) = P[X = x] = P(\{\omega \in \Omega : X(\omega) = x\})$$

Se verifica que:

1. $P(x) = 0$ si $x \notin \{x_1, x_2, \dots, x_n, \dots\}$.
2. $\sum_{x_i} P(x_i) = 1$.

En el ejemplo correspondiente al lanzamiento de la moneda:

$$\begin{aligned} P(0) &= P(X = 0) = P(\{\omega_4\}) = \frac{1}{4} \\ P(1) &= P(X = 1) = P(\{\omega_2\}) + P(\{\omega_3\}) = \frac{1}{2} \\ P(2) &= P(X = 2) = P(\{\omega_1\}) = \frac{1}{4} \\ P(x) &= P(X = x) = P(\emptyset) = 0 \text{ si } x \notin \{0, 1, 2\} \end{aligned}$$

Definición 3.2.2.— Dada una variable aleatoria discreta que toma los valores $x_1, x_2, \dots, x_n, \dots$ con $x_1 < x_2 < \dots < x_n < \dots$, se define la función de distribución asociada a X como:

$$F_X : \mathbb{R} \longrightarrow [0, 1]$$

$$F_X(x) = P[X \leq x] = \sum_{x_i \leq x} P(x_i)$$

La función de distribución asociada a la variable aleatoria descrita en el ejemplo 1 es:

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{4} & \text{si } 0 \leq x < 1 \\ \frac{3}{4} & \text{si } 1 \leq x < 2 \\ 1 & \text{si } x \geq 2 \end{cases}$$

Propiedades: Si F_X es la función de distribución asociada a una variable aleatoria X ,

1. F_X es escalonada y los puntos de salto son los x_i .
2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$ $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. F_X es no decreciente, esto es, si $x \leq y$ entonces $F_X(x) \leq F_X(y)$.
4. F_X es continua por la derecha.

3.3 Variables aleatorias continuas

Definición 3.3.1.— Una función $f : \mathbb{R} \longrightarrow \mathbb{R}$ es función de densidad de alguna variable aleatoria continua X si cumple

1. $f(x) \geq 0 \quad \forall x \in \mathbb{R}$.
2. $\int_{-\infty}^{+\infty} f(x)dx = 1$.

Además, para esa variable se verifica que

3. $P(a \leq X \leq b) = \int_a^b f(x)dx$ para $a, b \in \mathbb{R}$.

Nota: Si X es una variable aleatoria continua se verifica que $P(X = x) = 0 \quad \forall x \in \mathbb{R}$. Por tanto, no tiene sentido el cálculo de la probabilidad de que una variable aleatoria continua tome un determinado valor, sino que se trabaja con intervalos.

Definición 3.3.2.— Dada una variable aleatoria continua X y f_x su función de densidad, se define la función de distribución de X como:

$$F_x(x) = P(X \leq x) = \int_{-\infty}^x f_x(t)dt$$

Nota: como ya hemos dicho, si una variable aleatoria X es continua se verifica que $P[X = x] = 0 \quad \forall x \in \mathbb{R}$, y por tanto $P[X < x] = P[X \leq x] = F_x(x) \quad \forall x \in \mathbb{R}$.

Propiedades: La función de distribución F_x de una variable aleatoria continua X verifica

1. $\lim_{x \rightarrow -\infty} F_x(x) = 0 \quad \lim_{x \rightarrow +\infty} F_x(x) = 1$.
2. $P[a \leq X \leq b] = F_x(b) - F_x(a)$.
3. F_x es no decreciente y además es continua.
4. $F'_x(x) = f_x(x) \quad \forall x \in \mathbb{R}$ tal que f_x es continua en x .

3.4 Características asociadas a una variable aleatoria

Definición 3.4.1.— Si X es una variable aleatoria **discreta** que toma los valores x_1, x_2, x_3, \dots se define la **media o esperanza** de X como:

$$\mu_x = E[X] = \sum_{i \geq 1} x_i P[X = x_i]$$

Si X es continua, se define como:

$$\mu_x = E[X] = \int_{-\infty}^{+\infty} x f_x(x)dx$$

Si X es una variable aleatoria y $g(X)$ una función de dicha variable, se define la esperanza de $g(X)$ como:

$$E[g(X)] = \sum_{i \geq 1} g(x_i) P[X = x_i] \quad \text{si } X \text{ es discreta.}$$

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx \quad \text{si } X \text{ es continua.}$$

Propiedades:

1. $E[X + a] = E[X] + a$.
2. $E[aX] = aE[X]$.
3. $E[X + Y] = E[X] + E[Y]$.

Definición 3.4.2.— Se define la varianza de una variable aleatoria X como:

$$\text{Var}(X) = E[(X - \mu)^2] = \sum_{i \geq 1} (x_i - \mu_X)^2 \cdot P[X = x_i] \quad \text{si } X \text{ es discreta.}$$

$$\text{Var}(X) = E[(X - \mu)^2] = \int_{-\infty}^{+\infty} (x - \mu_X)^2 \cdot f_X(x) dx \quad \text{si } X \text{ es continua.}$$

En ambos casos se verifica: $\text{Var}[X] = E[X^2] - \mu_X^2$. También se denota $\text{Var}[X] = \sigma_X^2$. A la raíz cuadrada positiva de la varianza se le denomina desviación típica y se denota por σ_X .

Propiedades:

1. $\text{Var}[X + a] = \text{Var}[X]$.
2. $\text{Var}[aX] = a^2 \text{Var}[X]$.
3. Si X e Y son independientes (ver definición 3.5.3) entonces $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y]$.

3.4.1 Modelos de distribuciones discretas

Modelo Uniforme Discreto

Se describen a través de este modelo los experimentos aleatorios con N posibles resultados todos ellos equiprobables.

Definición 3.4.3.— Una variable aleatoria X se distribuye según un modelo uniforme discreto de parámetro N , y se denota por $X \sim U(N)$, si su función de probabilidad es

$$P[X = k] = \begin{cases} \frac{1}{N} & \text{si } k \in \{1, 2, \dots, N\} \\ 0 & \text{en caso contrario} \end{cases}$$

Proposición 3.4.4.— Si $X \sim U(N)$, entonces $E[X] = \frac{N+1}{2}$ y $\text{Var}[X] = \frac{(N+1)(N-1)}{12}$.

Modelo de Bernoulli

Definición 3.4.5.— *Un experimento de Bernoulli es aquel que sólo puede dar lugar a dos resultados: “éxito” (E), con probabilidad p o “fracaso” (F), con probabilidad $q = 1 - p$.*

Definición 3.4.6.— *Una variable aleatoria X se distribuye según un modelo de Bernoulli de parámetro p , y se escribe $X \sim Be(p)$, si su función de probabilidad viene dada por:*

$$P[X = k] = \begin{cases} p^k \cdot (1 - p)^{1-k} & \text{si } k \in \{0, 1\} \\ 0 & \text{en otro caso} \end{cases}$$

Usualmente se asocia el resultado éxito al valor 1 y fracaso al valor 0, esto es, $X(E) = 1$ y $X(F) = 0$.

Proposición 3.4.7.— *Si $X \sim Be(p)$, entonces $E[X] = p$ y $Var[X] = pq$.*

Modelo Binomial

Definición 3.4.8.— *Sean X_1, X_2, \dots, X_n variables aleatorias independientes e idénticamente distribuidas según un modelo $Be(p)$. La variable aleatoria $X = \sum_{i=1}^n X_i$ se distribuye según un modelo binomial de parámetros n y p , y se escribe $X \sim B(n, p)$.*

Puesto que cada X_i vale 0 en caso de fracaso y 1 en caso de éxito, X indica el número de éxitos obtenidos en una sucesión de n experimentos de Bernoulli.

Proposición 3.4.9.— *Si $X \sim B(n, p)$, entonces*

1. *La función de probabilidad de X es*

$$P[X = k] = \begin{cases} \binom{n}{k} \cdot p^k \cdot q^{n-k} & \text{si } k \in \{0, 1, \dots, n\} \\ 0 & \text{en otro caso} \end{cases}$$

2. *$E[X] = np$ y $Var[X] = npq$.*

3. *Si $p < 0.5$ y $np > 5$ o bien $p > 0.5$ y $nq > 5$ entonces $F_X(x) = P[X \leq x]$ se puede aproximar por $F_Y(x) = P[Y \leq x]$, donde $Y \sim N(np, npq)$ (distribución normal de media np y varianza npq).*

Modelo Geométrico

Definición 3.4.10.— *Dada una sucesión de experimentos de Bernoulli con probabilidad de éxito p , definimos la variable aleatoria X como el número de realizaciones del experimento hasta obtener el primer éxito. Se dice que X se distribuye según un modelo geométrico de parámetro p , y se denota por $X \sim Ge(p)$.*

Proposición 3.4.11.— Si $X \sim Ge(p)$, entonces

1. La función de probabilidad de X es

$$P[X = k] = \begin{cases} q^{k-1} \cdot p & \text{si } k \in \{1, 2, \dots, n, \dots\} \\ 0 & \text{en otro caso} \end{cases}$$

2. $E[X] = \frac{1}{p}$ y $Var[X] = \frac{q}{p^2}$.

Modelo de Poisson

Definición 3.4.12.— Una variable aleatoria X se distribuye según un modelo de Poisson de parámetro $\lambda > 0$, y se denota por $X \sim \mathcal{P}(\lambda)$ si su función de probabilidad es

$$P[X = k] = \begin{cases} \frac{\lambda^k}{k!} e^{-\lambda} & \text{si } k \in \{0, 1, 2, \dots\} \\ 0 & \text{en caso contrario} \end{cases}$$

La distribución de Poisson representa un buen modelo para la distribución de probabilidad del número de ocurrencias de un fenómeno en un espacio de tiempo o una región del espacio; por ejemplo: número de avisos de averías que se recibe cada hora en el servicio técnico de un determinado aparato.

Proposición 3.4.13.— Si $X \sim \mathcal{P}(\lambda)$ entonces

1. $E[X] = \lambda$ y $Var[X] = \lambda$.
2. Si λ es grande (> 20) entonces $F_X(x) = P[X \leq x]$ se puede aproximar por $F_Y(x) = P[Y \leq x]$, donde $Y \sim N(\lambda, \lambda)$ (distribución normal de media λ y varianza λ).
3. Dadas X_1, \dots, X_n independientes con $X_i \sim \mathcal{P}(\lambda_i)$, entonces

$$X_1 + \dots + X_n \sim \mathcal{P}(\lambda_1 + \dots + \lambda_n)$$

3.4.2 Modelos de distribuciones continuas

Modelo Uniforme Continuo

Definición 3.4.14.— Una variable aleatoria continua se distribuye según un modelo Uniforme continuo en el intervalo (a, b) , y se denota por $X \sim U(a, b)$, si su función de densidad es constante dentro del intervalo, y nula fuera de él, esto es

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in (a, b) \\ 0 & \text{en caso contrario} \end{cases}$$

Proposición 3.4.15.— Si $X \sim U(a, b)$, entonces $E[X] = \frac{a+b}{2}$ y $Var[X] = \frac{(b-a)^2}{12}$.

Modelo Exponencial

Definición 3.4.16.— Una variable aleatoria X se distribuye según un modelo exponencial de parámetro $\lambda > 0$, y se denota por $X \sim \text{Exp}(\lambda)$, si su función de densidad es

$$f(x) = \begin{cases} \lambda \cdot e^{-\lambda \cdot x} & \text{si } x > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

La distribución exponencial es de gran utilidad cuando se desea modelar el tiempo que transcurre entre las ocurrencias de un determinado fenómeno, por ejemplo: tiempo entre averías. Guarda una estrecha relación con el modelo de Poisson: si el número de veces que ocurre un fenómeno en un determinado intervalo de tiempo sigue una distribución de Poisson, entonces el tiempo entre ocurrencias de ese fenómeno sigue una distribución exponencial y viceversa.

Proposición 3.4.17.— Si $X \sim \text{Exp}(\lambda)$, entonces $E[X] = \frac{1}{\lambda}$ y $\text{Var}[X] = \frac{1}{\lambda^2}$.

Modelo Normal

Es el modelo más importante de todos, ya que son muchos los fenómenos naturales y sociales que se ajustan a dicho modelo, y en otros casos en los que la variable no se ajusta a un modelo normal, ciertas funciones muestrales sí siguen dicha distribución.

Definición 3.4.18.— Una variable aleatoria X se distribuye según un modelo Normal de media $\mu \in \mathbb{R}$ y varianza $\sigma^2 \in \mathbb{R}^+$, y se denota por $X \sim N(\mu, \sigma^2)$ si su función de densidad es

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} \quad \forall x \in \mathbb{R}$$

El estudio de la función de densidad muestra una serie de propiedades de dicha función:

1. La curva es simétrica respecto a la recta vertical $x = \mu$.
2. Tiene un máximo en μ y puntos de inflexión en $\mu - \sigma$ y $\mu + \sigma$.
3. Presenta la asíntota horizontal $y = 0$.
4. La densidad de probabilidad de X está concentrada en torno a μ y en el intervalo $(\mu - 3\sigma, \mu + 3\sigma)$.

Proposición 3.4.19.— Si $X \sim N(\mu, \sigma^2)$, entonces

1. $E[X] = \mu$ y $\text{Var}[X] = \sigma^2$.
2. $\frac{X-\mu}{\sigma} \sim N(0, 1)$.
3. Dadas X_1, \dots, X_n independientes con $X_i \sim N(\mu_i, \sigma_i^2)$, entonces

$$b + a_1 X_1 + \dots + a_n X_n \sim N\left(b + \sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

4. Si $Z \sim N(0, 1)$ entonces $P[Z \leq a] = P[Z \geq -a]$, $\forall a \in \mathbb{R}$.

3.5 Variables bidimensionales

Supongamos que en una población queremos estudiar dos características que vienen descritas por dos variables aleatorias X e Y . La observación conjunta de ambas características sobre cada individuo se traduce en una variable aleatoria bidimensional (X, Y) que es discreta (continua) si X e Y son discretas (continuas).

Si X e Y son discretas, denotaremos por $\{x_1, \dots, x_i, \dots\}$ al conjunto de valores que puede tomar X y por $\{y_1, \dots, y_j, \dots\}$ al conjunto de valores que puede tomar Y .

Definición 3.5.1.— Si (X, Y) es una variable aleatoria bidimensional discreta se define su función de probabilidad conjunta como:

$$P_{X,Y}(x, y) = P[X = x; Y = y] \quad \forall (x, y) \in \mathbb{R}^2$$

Propiedades: Si (X, Y) es una variable aleatoria bidimensional discreta,

- Si $x \notin \{x_1, \dots, x_i, \dots\}$ o bien $y \notin \{y_1, \dots, y_j, \dots\}$, entonces $P[X = x; Y = y] = 0$.
- $\sum_{x_i, y_j} P[X = x_i; Y = y_j] = 1$.

Definición 3.5.2.— Una función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ es función de densidad conjunta de alguna variable aleatoria bidimensional continua (X, Y) si cumple:

1. $f(x, y) \geq 0 \quad \forall (x, y) \in \mathbb{R}^2$.
2. $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dy dx = 1$.

Además, para esa variable se verifica que

$$3. P[a \leq X \leq b; c \leq Y \leq d] = \int_a^b \int_c^d f(x, y) dy dx \quad \forall a, b, c, d \in \mathbb{R}.$$

Nota: Si (X, Y) es una variable aleatoria bidimensional, se define su función de distribución conjunta como $F_{X,Y}(x, y) = P[X \leq x; Y \leq y]$ que posee propiedades similares a las que ya vimos para las funciones de distribución de variables aleatorias unidimensionales. El cálculo efectivo de dicha función de distribución conjunta dependerá del carácter discreto o continuo de la variable bidimensional, aunque no profundizaremos en este aspecto.

Definición 3.5.3.— Dos variables X e Y son independientes si y sólo si

$$P[X = x; Y = y] = P[X = x] \cdot P[Y = y] \quad \text{si } X \text{ e } Y \text{ son discretas.}$$

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y) \quad \text{si } X \text{ e } Y \text{ son continuas.}$$

Propiedades: Si X e Y son independientes, entonces:

1. $E[XY] = E[X] \cdot E[Y]$.
2. $Var[X + Y] = Var[X] + Var[Y]$.

Los recíprocos no son, en general, ciertos.

V. a. discretas	Interpretación	Función de probabilidad	Esperanza y Varianza	Relación con otras variables
Bernoulli $Be(p)$	Experimento aleatorio con dos posibles resultados: E, F. $P(E) = p$; $P(F) = 1-p = q$	$P[X=k] = p^k q^{1-k}$ $k=0,1$	$E[X] = p$ $Var[X] = pq$	Si $X_1, \dots, X_n \sim Be(p)$ independientes, entonces $X_1 + \dots + X_n \sim B(n, p)$
Binomial $B(n, p)$	Número de éxitos en la realización de n experimentos de Bernoulli independientes	$P[X=k] = \binom{n}{k} p^k q^{n-k}$ $k=0,1,\dots,n$	$E[X] = np$ $Var[X] = npq$	Si $p < 0.5$ y $np > 5$ o bien $p > 0.5$ y $nq > 5$ se puede aproximar por $N(np, npq)$
Geométrica $Ge(p)$	Número de ensayos hasta la obtención del primer éxito en una sucesión de experimentos de Bernoulli.	$P[X=k] = q^{k-1} p$ $k=1,2,3,\dots$	$E[X] = 1/p$ $Var[X] = q/p^2$	-----
Poisson $P(\lambda)$	Número de ocurrencias de un fenómeno en un intervalo de tiempo o región del espacio.	$P[X=k] = \frac{e^{-\lambda} \lambda^k}{k!}$ $k=0,1,2,3,\dots$	$E[X] = \lambda$ $Var[X] = \lambda$	Si λ es grande (>20), se puede aproximar por $N(\lambda, \lambda)$ Si $X_1 \sim P(\lambda_1)$ y $X_2 \sim P(\lambda_2)$ independientes, entonces $X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$
Uniforme discreta $U(N)$	Experimento aleatorio con N posibles resultados equiprobables	$P[X=k] = 1/N$ $k=1,2,\dots,N$	$E[X] = (N+1)/2$ $Var[X] = (N+1)(N-1)/12$	-----

V.a. continuas	Interpretación	Función de densidad	Esperanza y Varianza	Relación con otras variables
Uniforme $U(a,b)$	Densidad de probabilidad repartida uniformemente en el intervalo (a,b)	$f(x) = 1/(b-a)$ $x \in (a,b)$	$E[X] = \frac{a+b}{2}$ $Var[X] = \frac{(b-a)^2}{12}$	-----
Normal $N(\mu, \sigma^2)$	Densidad de probabilidad concentrada en torno a μ y en el intervalo $(\mu - 3\sigma, \mu + 3\sigma)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$ $\forall x \in R$	$E[X] = \mu$ $Var[X] = \sigma^2$	$\frac{X - \mu}{\sigma} \sim N(0,1)$ Si $X_1 \sim N(\mu_1, \sigma_1^2)$ y $X_2 \sim N(\mu_2, \sigma_2^2)$ independientes, entonces $aX_1 + bX_2 + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$
Exponencial $Exp(\lambda)$	Tiempo entre ocurrencias de un determinado fenómeno	$f(x) = \lambda e^{-\lambda x}$ $x > 0$	$E[X] = \frac{1}{\lambda}$ $Var[X] = \frac{1}{\lambda^2}$	-----